YOLOV3

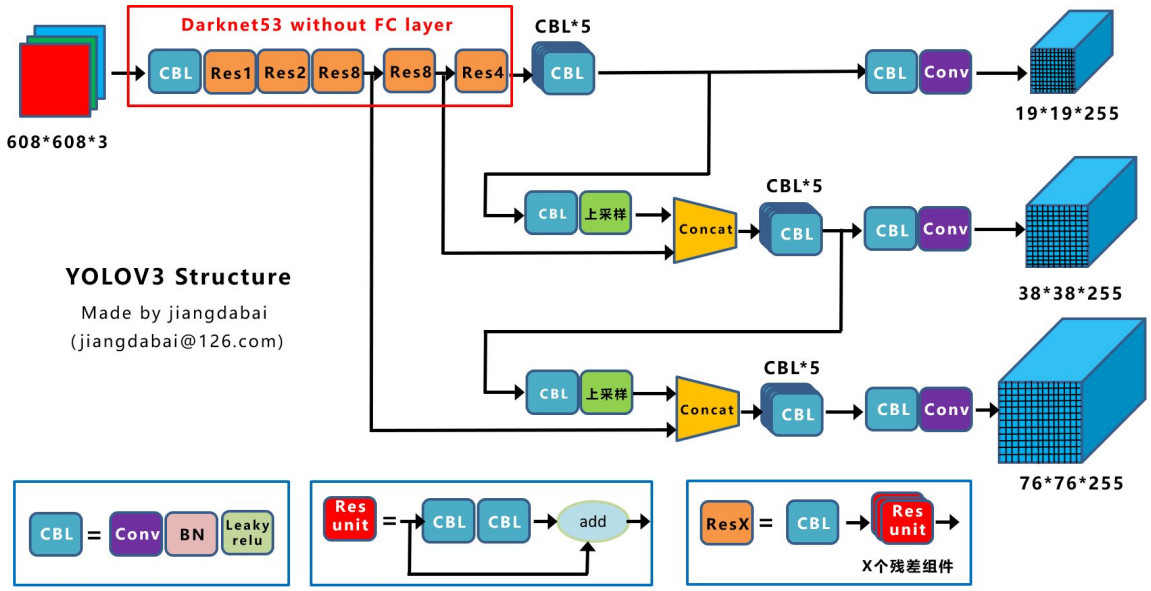

- Resunit 借助于Resnet网络中的残差结构为了使用网络训练的更深
- CBL结构 conv+BN+leaky relu函数
- 整体采用的FPN同SSD300的思路一致，小尺寸的feature map的感受野较大 用于检测较大的物体
- concat 对应的size相同，在channel所在维度上进行concat
- add 同 shortcut一致，channels数相同，H,w对应数值相加

  backbone网络的整体结构是Darknet-53,带有对应的全连接图

	Type	Filters	Size	Output
	Convolutional	32	3 × 3	256 × 256
	Convolutional	64	3 × 3 / 2	128 × 128
	Convolutional	32	1 × 1	
1×	Convolutional	64	3 × 3	
	Residual			128 × 128
	Convolutional	128	3 × 3 / 2	64 × 64
	Convolutional	64	1 × 1	
2×	Convolutional	128	3 × 3	
	Residual			64 × 64
	Convolutional	256	3 × 3 / 2	32 × 32
	Convolutional	128	1 × 1	
8×	Convolutional	256	3 × 3	
	Residual			32 × 32
	Convolutional	512	3 × 3 / 2	16 × 16
	Convolutional	256	1 × 1	
8×	Convolutional	512	3 × 3	
	Residual			16 × 16
	Convolutional	1024	3 × 3 / 2	8 × 8
	Convolutional	512	1 × 1	
4×	Convolutional	1024	3 × 3	
	Residual			8 × 8
	Avgpool		Global	
	Connected		1000	
	Softmax			

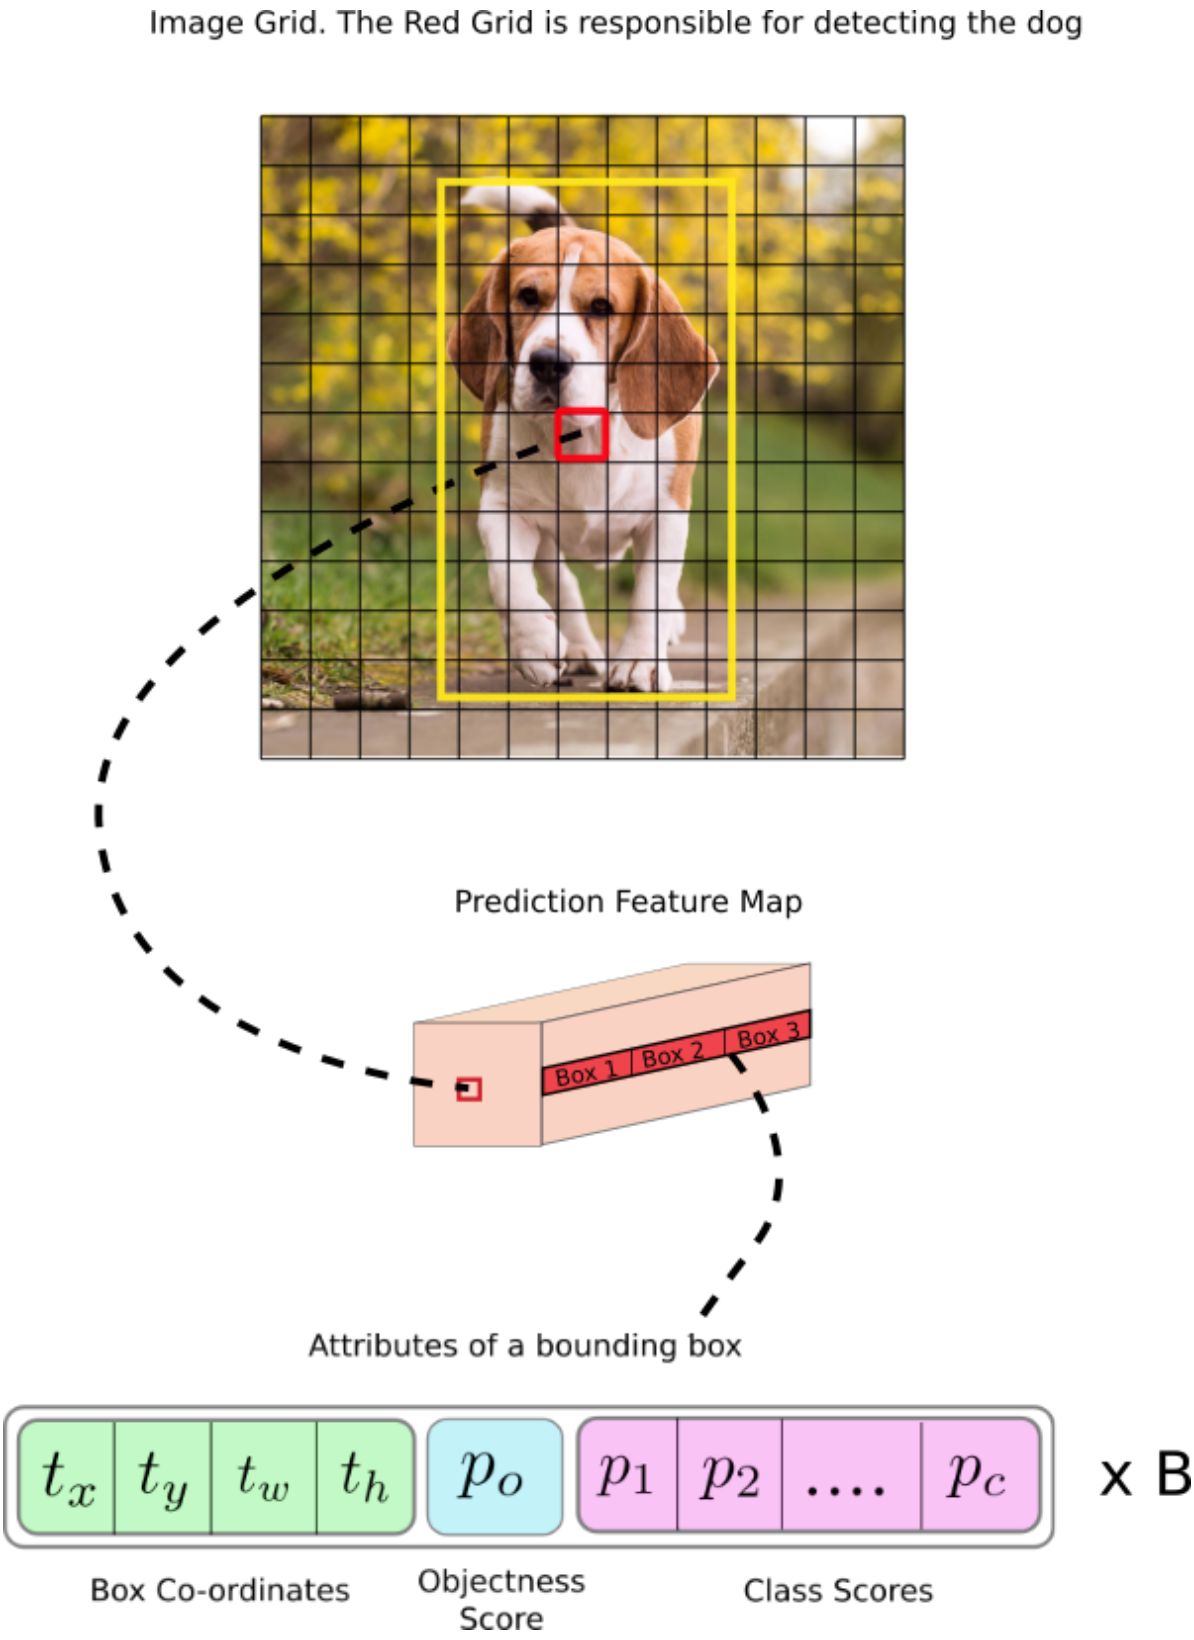

预测公式

$$b_x = \sigma(t_x) + c_x \tag{1}$$

$$b_y = \sigma(t_y) + c_y \tag{2}$$

$$b_w = p_w e^{t_w} \tag{3}$$

$$b_h = p_h e^{t_h} \tag{4}$$

上述左面的表达式代表着对应的预测的高宽，和中心点对应的x，y左边，t_x,t_y,w_w,t_h是网c_x和c_y是网格对应的左上角的坐标，对应的pw,ph为对应的anchor的高宽 ,σ是对应的激活函数sigmoid

Center coordinates

sigmoid函数强制中心坐标的值介于对应0-1之间

- yolo预测的offset是相对值坐标，即当前grid的左上角的方面
- 对应的feature map中的维度归一化

上述doge的图像位于（6.6）sigmoid输出的限制在0-1之间，如果预测的 x,y 坐标大于 1，例如 (1.2, 0.7)，会发生什么。这意味着中心位于 (7.2, 6.7)。请注意，中心现在位于我们红色单元格右侧的单元格中，或第 7 行中的第 8 个单元格。**这打破了 YOLO 背后的理论，**因为如果我们假设红框负责预测狗，那么狗的中心必须位于红细胞中，而不是旁边的那个

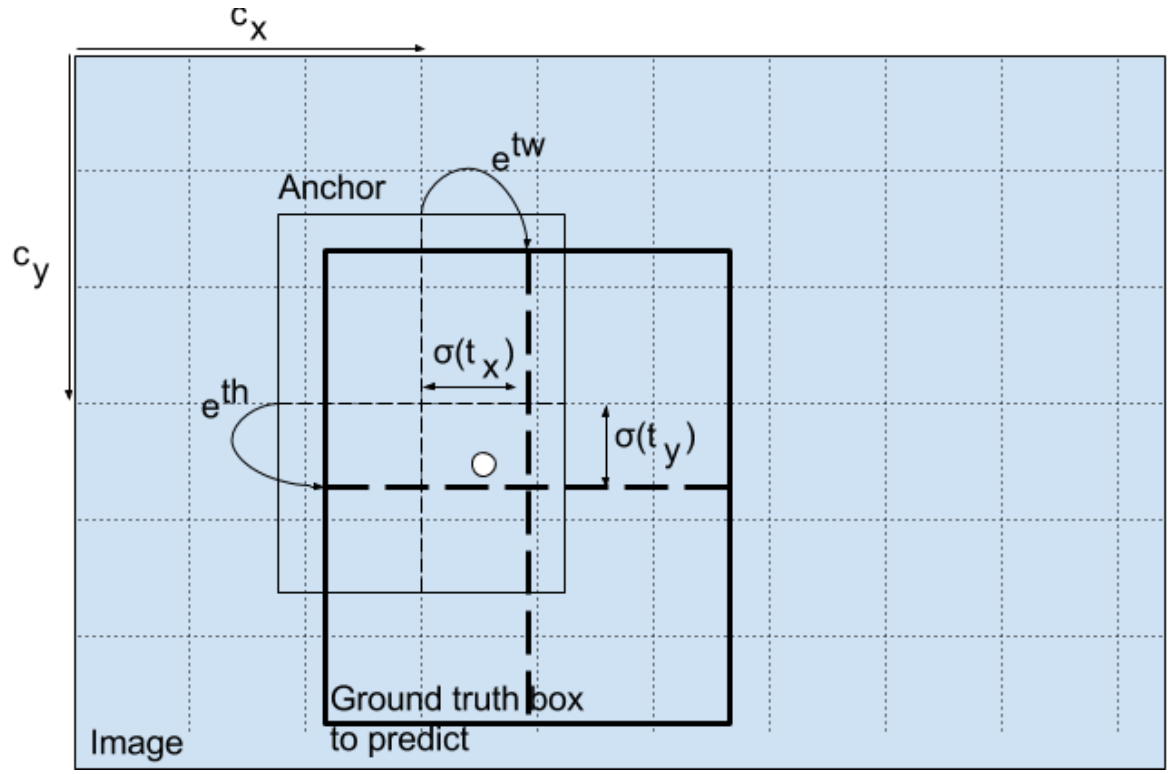

SSD和Faster RCNN中的理论大概一致，都是通过高宽和平移的变化，平移和缩放两个主要的步骤来完成的，SSD中l_x为对应prior_box的特征向量，对应的网络权重直接变换的，在高宽缩放上yolo系列大致与两个经典的网络一致，中心坐标的平移则是缺少对应的先验框的高宽长度，仅依赖于求出σ的线性变化来进行regression操作

上述的g代表镇Faster RCNN 中 d为default box,g 代表着ground truth box中的结果

给定一组的default box $ d=(d_{cx},d_{cy},d_w,d_h)$和一组Ground truth $GT=(g_x,g_y,g_w,g_h)$ 找到一组线性变换满足，可以使得default box近似于对应的Ground truth的数据，可以进行平行和缩放的处理

$$G'_x = d_w l_x(d) + d_x \tag{2}$$

$$G'_w = d_w exp(l_w(d)) \tag{3}$$

所以当前需要的就是几个线性变换的参数L_*代指各个x,y,w,h等四个变换如何获得对应，所以利用线性回归的方法计算$Y = w_*^T d_*$d_*代表着feature map中的特征向量计算上述公式的l^i

产生的预测*bw*和*bh*由图像的高度和宽度归一化。（训练标签是这样选择的）。因此，如果包含狗的盒子的预测*bx*和*by*是 (0.3, 0.8)，那么 13 x 13 特征图上的实际宽度和高度是 (13 x 0.3, 13 x 0.8)。

Object score

判断当前grid是否存在物体的概率，对于狗狗所在的grid和相邻的狗日的该值为1，图像的其他区域也为对应的0，这也是一个二分类的问题，所以对应的函数也为sigmoid

class score

类别得分，在yolov3中，作者选用sigmoid代替，softmax默认各个类之间是互相排斥的

但是如果存在女人和人等等两个类别，对应的假设就不太可能成立，这就是避免使用softmax的reason

多尺度判别

会搞这张network上，分别选择三个scale上进行prediction，由于feature map的size大小，根据FPN中的思想，金字塔的顶端的单个像素的receptive field会更大，所以可以检测较大的物体，同理较低的网络能够捕捉更小的object。

yolo V3在三个不同的尺度上进行预测。检测图利用三种不同大小的feature map进行对应的detection

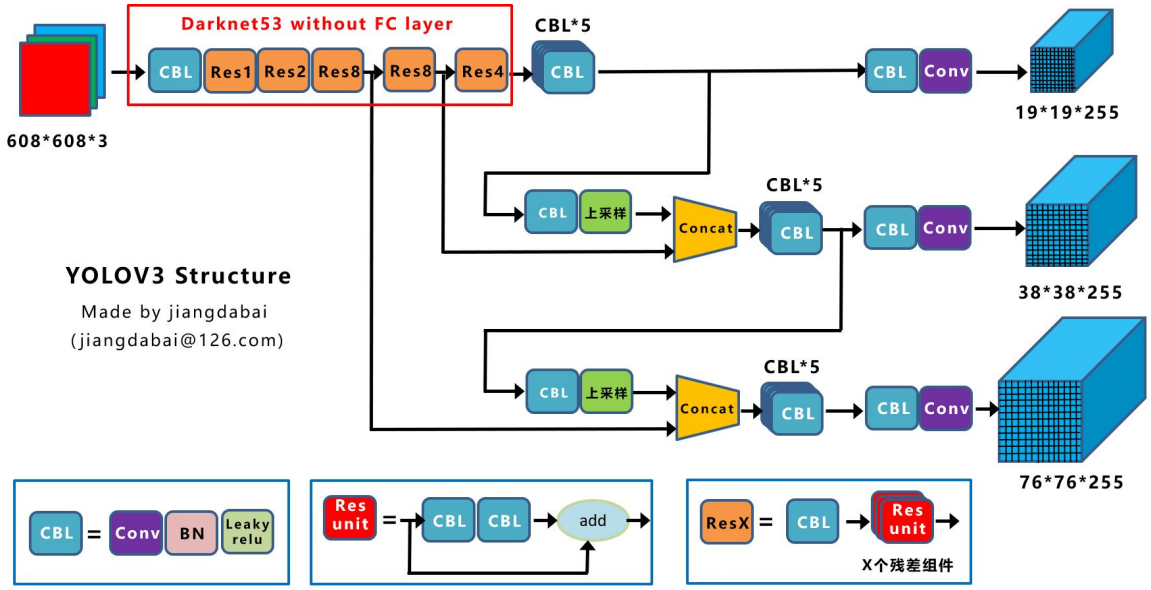

每个feature map中单个pixel产生对应的anchor的数量为3个

- feature map1 (52×52) stride=8
- feature map2(26×26) stride=16
- feature map3 13*13   stride=32

所以网络中产生的anchor的总数对应为10647个anchors

每个scale上，每个grid利用三个anchor预测3个对应bounding box进行对应的regression操作使得anchor的数量为9个。

将网络先前层的特征图，进行对应的上采样，然后在channel所在的维度上进行对应的concat操作，来获取向前层更多的语义信息，然后添加若干层去处理这个组合的特征图。总共应用到两个上采样层，在第三个scale维度特征图处理结束后，预测网路中已经融合网络早期的细粒度特征。

先验框的ratio根据之前版本的yolo系列，进行k-means的聚类的方法，3个scale的prior box分别为(10×13),(16×30),(33×23),(30×61),(62×45),(59× 119),(116 × 90),(156 × 198),(373 × 326).

筛选方法

记录所在box的特征向量的object score通过阈值筛选掉一部分的anchor

NMS 方法，同样也是设定阈值，IOU的过高的anchor直接筛选掉

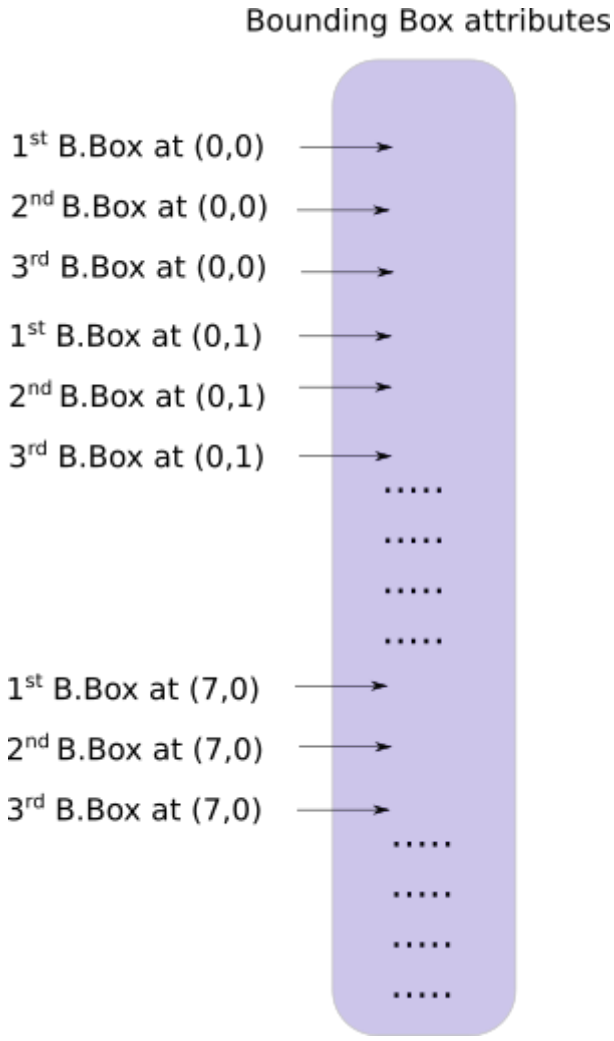

网络实现

解析对应的cfg文件

```
[net]
# Testing
batch=1
subdivisions=1
# Training
# batch=64
# subdivisions=16
width= 320
height = 320
channels=3
momentum=0.9
decay=0.0005
angle=0
saturation = 1.5
exposure = 1.5
hue=.1
learning_rate=0.001
burn_in=1000
max_batches = 500200
policy=steps
steps=400000,450000
scales=.1,.1
[convolutional]
batch_normalize=1
```

```
filters=32
size=3
stride=1
pad=1
activation=leaky
# Downsample
[convolutional]
batch_normalize=1
filters=64
size=3
stride=2
pad=1
activation=leaky
[route]
layers = -4

[route]
layers = -1, 61

```

yolov3中的配置文件如上述，大体可以分为五个层

- CBL
- short cut
- upsample 利用双线性采样的因子对于前一层的feature map进行对应的处理
- route layers route仅有对应的一个值是，输出该索引值的特征图，-4代表着从该Route层向前输出第四个的特征图，route的value如果存在两个的话则是上面提出的concat的操作,沿深度方向上进行操作

```
[yolo]
mask = 0,1,2
anchors = 10,13,  16,30,  33,23,  30,61,  62,45,  59,119,  116,90,  156,198,  373,326
classes=80
num=9
jitter=.3
ignore_thresh = .5
truth_thresh = 1
random=1
```

anchors描述了9个anchor，利用mask标签作为索引，因为一个pixel上只有对应的3个anchor，然后三个scale所以说总共有9个anchors

```
def parse_cfg(cfgfile):
    """
    Takes a configuration file

    Returns a list of blocks. Each blocks describes a block in the neural
    network to be built. Block is represented as a dictionary in the list

    """
    block = {}
    blocks = []

for line in lines:
    if line[0] == "[":               # This marks the start of a new block
```

```
        if len(block) != 0:          # If block is not empty, implies it is storing values of previous block.
            blocks.append(block)     # add it the blocks list
            block = {}               # re-init the block
        block["type"] = line[1:-1].rstrip()  #生成对应的type，
    else:
        key,value = line.split("=")
        block[key.rstrip()] = value.lstrip()
blocks.append(block)

return blocks
```

```
[net]
# Testing
batch=1
subdivisions=1
# Training
# batch=64
# subdivisions=16
width= 320
height = 320
channels=3
momentum=0.9
decay=0.0005
angle=0
saturation = 1.5
exposure = 1.5
hue=.1
```

forward

在前面的多尺度判别中，我们得到三种不同的scale的feature map，根据k-means中，在对应的feature map中，单个grid分配了三种anchor，对应的采样倍数也同样获得，让我们重新思考下，单个特征图输出的channels(1+4+80)*3*获得所需要的*channels*的数量，*85*、3=255个对应的channels

我们将特征图reshape为(B,C,H,W)reshape成对应的下面的维度，简单来说就是将三维的tensor->转换到对应的2

最后输出的(B,H*W*num_anchors,bbox_attrs),下面是维度转换具体的方式

(batch_size,box_attrs*num_anchors,grid_size,grid_size)

(batch_size,gridsize*gridsize,bbox_attrs*num_anchors)

(batch_size,gridsize*gridsize*num_anchors,bbox_attrs)

decode

正如之前提到的公式，按照知乎大佬的输出,在第二个特征图中(5,4,2)代表的意思是，第二个特征图中的cy=5,cx=4,mask=2,59,119作为anchor的w和h，计算之后的b_x要乘上对应的下采样率，得到对应的真实框的x,y

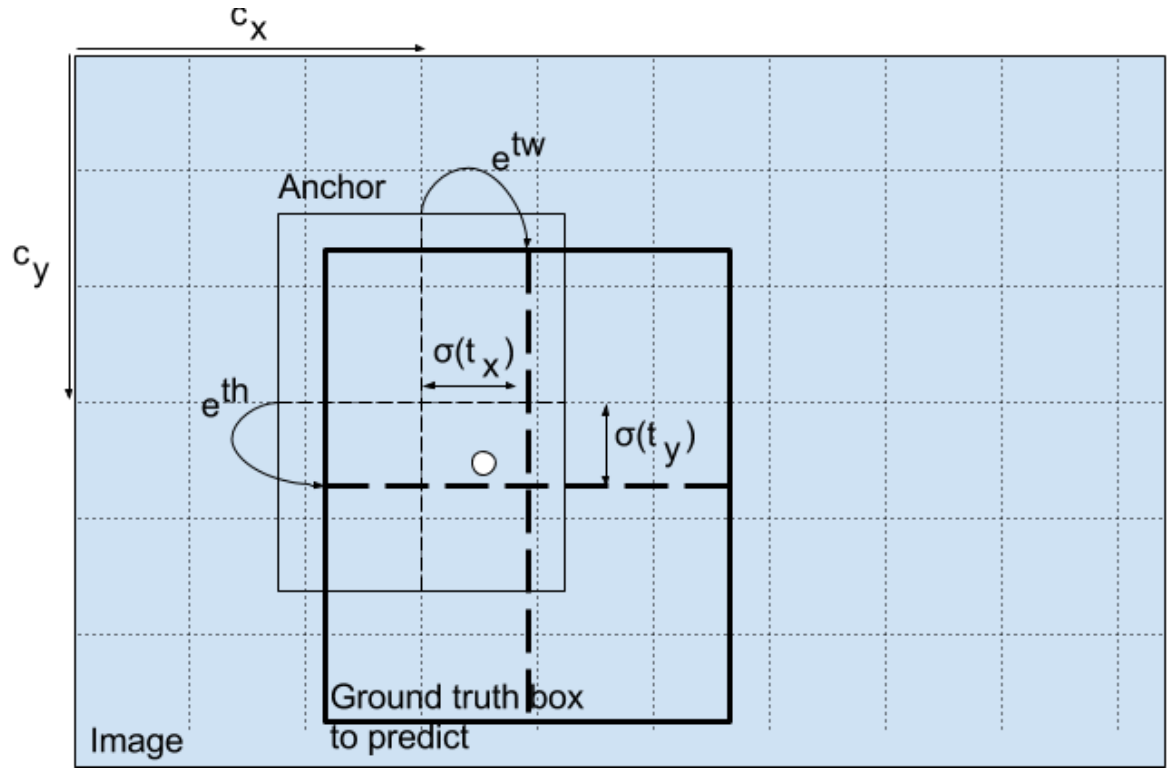

回到网络主体中，由于anchor由size是相当于对应的原始图像，所以在前向传播过程中也需要将size进行下采样

接下来是激活函数，需要对prediction cx cy objectscore 进行sigmoid处理，具体

代码实现

```
def predict_transform(prediction,inp_dim,anchorsm,num_classes)
"""
input:
    prediction (batch,255,grid,grid)
    inp_dim inputQ_figure shape(3,412,412)
    anchors shape(3,2) current feature map shape
    num_classes CoCo default classes=80
output:
    prediction
"""
    batch_size = prediction.size(0)#当前的batch_size
    stride =  inp_dim // prediction.size(2)#size(2)为当前特征图的size
    grid_size = inp_dim // stride#获取对应的grid size
    bbox_attrs = 5 + num_classes#channels 80+1+4
    num_anchors = len(anchors)#shape(batch,grid*grid,2)
    prediction = prediction.view(batch_size, bbox_attrs*num_anchors,
grid_size*grid_size)
    prediction = prediction.transpose(1,2).contiguous()
    prediction = prediction.view(batch_size,
grid_size*grid_size*num_anchors, bbox_attrs)
    anchors = [(a[0]/stride, a[1]/stride) for a in anchors]#anchors
downsample 进行对应下采样
    prediction[:,:,0] = torch.sigmoid(prediction[:,:,0])# cx
    prediction[:,:,1] = torch.sigmoid(prediction[:,:,1])# cy
    prediction[:,:,4] = torch.sigmoid(prediction[:,:,4])# object score grid
的置信度


```

decode 部分(regression)

下面具体描述下上述的操作

```
grid=np.arange(grid_size)
a,b=np.meshgrid(grad,grid)#default mode “xy" a,b shape(grid_size,grid_size)
#a 二维坐标对应的axis=0 部分的值 b为 axis=1 部分的值，此处的目的生成一个(32*32,1)的tensor
x_offset=torch.Floattensor(a).view(-1,1)
y_offset=torch.FloatTensor(b).view(-1,1)
x_y_offset=torch.cat((x_offset,y_offset),axis=1).repeat(1,3).unsqueeze(0)
#下面介绍一下矩阵的shape的变换情况
#feature map (52,52) shape (2704,2)->(2704,6)->(1,2704,6)
#decode part
prediction[:,:,:2]+=x_y_offset
```

```
#接下来是高宽的部分，anchor size为(3,2)
anchors=torch.FloatTensor(anchors)
anchors=anchor.repeat(grid*grid,1).unsqueeze(0)#shape (3,2)->(2704*3,2)->(1,2704*3,2)
predictions[:,:,2:4]=torch,exp(predictions{:,:,2:4})*anchors#罗实现对应广播的操作
```

classification

```
prediction[:,:,5: 5 + num_classes] = torch.sigmoid((prediction[:,:, 5 : 5 + num_classes]))
```

实现上述的sigmoid的输出，将原来的图映射到对应的实际的大小

```
predictions[:,:,:4]*=stride
```

下面的部分需要将三种不同scale的feature map需要连接起来，代码部分设计了一个write 作为flag

如果write=0,默认是第一张feature map 的prediction的部分，write=1部分则将接下来feature map在dim=1处进行concat操作,这样的操作时，无法创建一个空的tensor进行concat的操作方法

```
if not write:
    detection=x
    write=1
else:
    detections=torch.cat((dections,x),dim=1)
```

预训练的部分

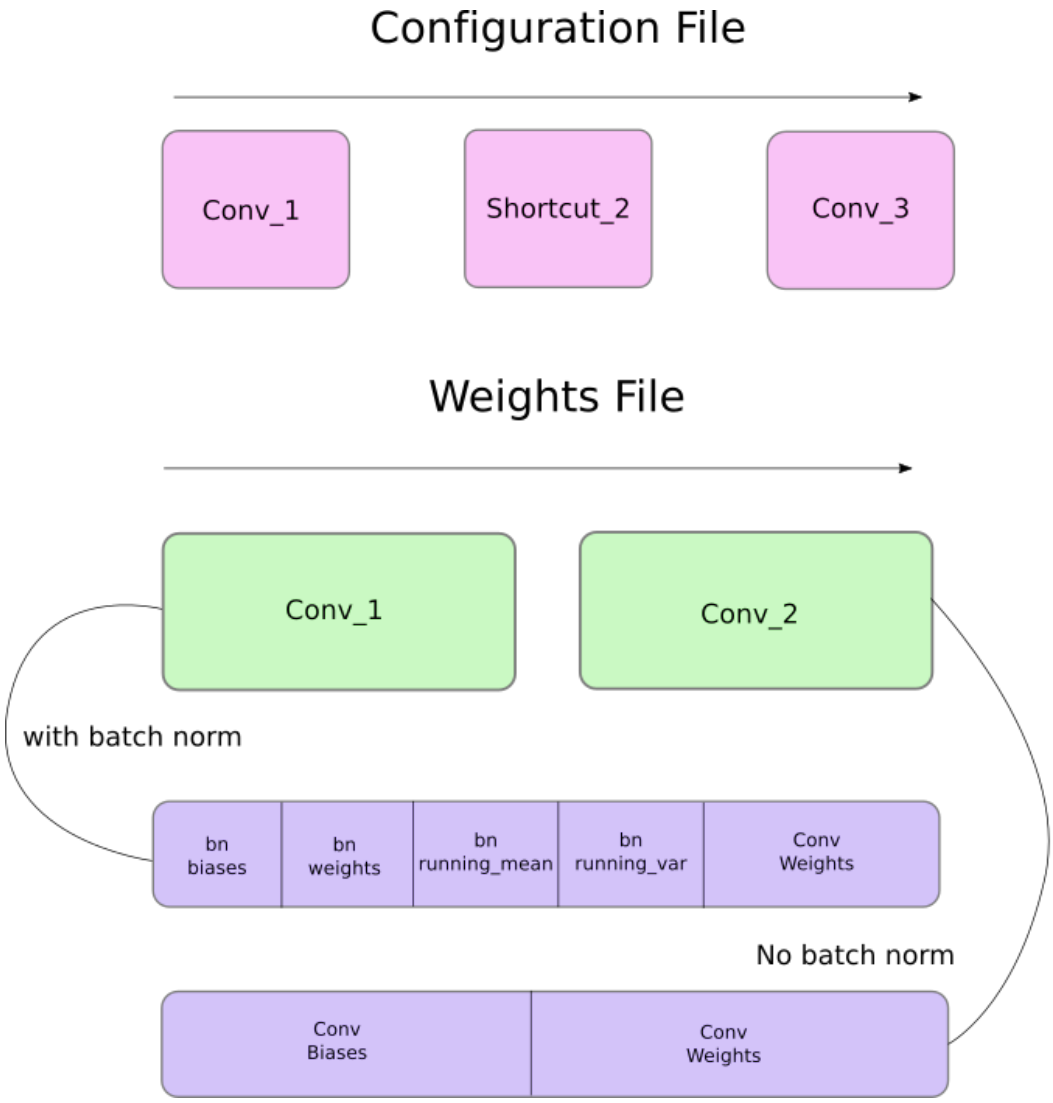

权重只属于两张参数，BN层和CONV层,权重的存储在上面已经体现好了